DOSSIER TECHNIQUE ET GUIDE D’ACHAT

La station IA de Yoann

PC professionnels, LLM 20B à 120B+, fournisseurs cloud, agents de code et migration d’Agent Crypto.

QUESTION À TRANCHER

Avec un budget de 3 000 à 5 000 € TTC, quelle machine permet de travailler professionnellement sur Agent Crypto tout en exécutant de grands modèles locaux, sans confusion entre capacité mémoire, vitesse et indépendance ?

ÉDITION LONGUE · 31 OCTOBRE 2026

Destinataire : Yoann. Document de lecture et de décision, optimisé au format A5 pour Samsung, ordinateur et partage Messenger.

Ce dossier développe les comparaisons et recommandations issues du fil de discussion. Il ne reproduit pas les échanges personnels et n’expose pas le contenu privé des archives. Les prix indiqués doivent être reconfirmés au moment de l’achat.

Avant de commencer : les trois idées essentielles

1. Pour un LLM de 120B, la mémoire est le premier verrou. Un processeur Ryzen 9 haut de gamme associé à 16 ou 32 Go de VRAM peut exceller en codage, mais ne suffit pas à charger entièrement en GPU les poids 4 bits d'un modèle dense de 120 milliards de paramètres.

2. Charger un modèle ne signifie pas l'utiliser rapidement. Les mini-stations 128 Go accueillent de grands modèles quantifiés, mais l'inférence, surtout sur les modèles denses, sera plus lente que sur un GPU NVIDIA professionnel dont toute la charge tient en VRAM. Le type de modèle et le runtime influencent le résultat autant que la fiche commerciale.

3. LLM, logiciel agent et routeur cloud sont trois couches distinctes. Kimi, Claude, DeepSeek et Qwen désignent des modèles ou des plateformes ; Kimi Code, Claude Code, OpenCode et Vibe Code sont des environnements de travail ; OpenRouter permet d'accéder à plusieurs moteurs via une API commune. Aucun ne remplace à lui seul la mémoire documentaire du projet.

DÉCISION PROPOSÉE

Pour le budget confirmé de Yoann, privilégier une mini-station Ryzen AI Max+ 395 avec 128 Go de mémoire unifiée. Premier choix : GMKtec EVO-X3. Alternative orientée réseau et exploitation : Minisforum MS-S1 MAX. Prévoir sauvegardes, onduleur, contrôles et essais locaux avant de confier du code ou des actions au LLM.

Ce que l’on sait / ce que l’on ne sait pas

- **Vérifié :** fiches officielles GMKtec, Minisforum et Beelink ; spécifications NVIDIA/Apple ; mesures AMD pour Qwen 9B/35B/122B ; politiques et tarifs d’OpenRouter, Kimi, Claude, Gemini et Mammouth.
- **Estimé :** coûts des accessoires, coût complet d’exploitation, vitesse sur Windows et niveau de confort subjectif.
- **Non testé dans le fil :** installation effective chez Yoann, comportement du Bridge sur la machine choisie, vitesse réelle d’un 120B dense, qualité des IA sur le dépôt privé.

Sommaire détaillé

PARTIE I — Comprendre les besoins et les LLM locaux
01. Cahier des charges pour Agent Crypto
02. Paramètres, quantification, contexte et MoE
03. Pourquoi la VRAM ne se résume pas à la RAM
04. Benchmarks : ce que mesurent réellement les tokens/s
PARTIE II — Panorama des ordinateurs
05. Tour Ryzen 7 / tour Ryzen 9
06. Ryzen AI Max+ 395 : les trois mini-stations 128 Go
07. Stations NVIDIA, DGX Spark, Apple, Framework
08. Tableau des huit familles de configuration
PARTIE III — Achat dans les 3 000–5 000 €
09. Devis GMKtec complet et budgets alternatifs
10. Minisforum / Beelink : atouts et réserves
11. Top 3 final et critères de choix
PARTIE IV — Modèles et fournisseurs d’IA
12. Claude, Gemini, Kimi, Mistral, DeepSeek, Qwen
13. GLM, MiniMax, Grok et modèles locaux
14. OpenRouter : bénéfices, tarification, confidentialité
15. Mammouth AI : quotas et modèle économique
16. Agents de développement : Kimi Code, Claude Code, OpenCode
PARTIE V — Installation et validation
17. Architecture Windows, Bridge et mémoire locale
18. Référentiel de test et contrôle des risques
19. Plan de déploiement, checklist achat et décisions
Annexes : calculs, lexique et sources vérifiables

PARTIE I

Comprendre le besoin

Avant de comparer les machines, déterminer la charge de travail réelle et les limites des grands modèles.

01 · Le cahier des charges de Yoann

Le poste doit d'abord être un **ordinateur de travail professionnel stable** : navigateur Firefox, interface web Administrator/Trader/Operator, Bridge Windows, backend, Git et éditeur de code. L'ajout d'un LLM local doit renforcer ce poste, pas bloquer l'interface lorsque le GPU est occupé.

Les quatre usages à séparer

- **Exploitation d'Agent Crypto :** affichage des graphiques, récupération des données de marchés, diagnostics du scanner, usage du Bridge, lecture de journaux et contrôle d'accès.
- **Développement et maintenance :** ouvrir un dépôt réel, comparer des versions, tracer une fonction, proposer un diff, lancer des vérifications, préparer des livrables.
- **Inférence locale :** interroger un modèle sans envoyer les documents à un fournisseur distant, conserver une API locale et un environnement à mémoire contrôlée.
- **Continuité documentaire :** retrouver la bonne règle ou le bon module à partir de Git, Notion exporté ou archives ; ne pas confondre « fichier présent » et « fichier lu et appliqué ».

Exigences minimales d’un poste sérieux

Un poste exploitable doit réserver de l’espace au système, aux outils de développement, aux archives, aux sauvegardes et aux modèles. Les modèles quantifiés peuvent occuper de quelques gigaoctets à plus de 100 Go chacun. Plusieurs NVMe ou un grand SSD deviennent vite utiles.

- Windows 11 Pro ou équivalent pour le Bridge existant ; accès administrateur contrôlé ; chiffrage du disque ; mises à jour planifiées.
- 128 Go de mémoire unifiée pour l’objectif 120B à coût raisonnable, ou 96 Go de VRAM dédiée dans une station professionnelle onéreuse.
- 2 To SSD minimum à l’achat, de préférence 4 à 6 To internes au total à moyen terme.
- Réseau Ethernet fiable ; sauvegarde externe chiffrée ; alimentation protégée ; refroidissement continu.

CONTRAINTE NON NÉGOCIABLE

Ne jamais associer « peut exécuter localement un LLM de 120B » à « peut développer, générer des vidéos, analyser des données et servir plusieurs utilisateurs à pleine vitesse simultanément ». Ce sont des critères distincts.

02 · Que signifie 20B, 70B ou 120B ?

Le suffixe B signifie **milliard de paramètres**. Il indique la taille d’un modèle, pas directement sa qualité. Un modèle de 35B bien entraîné peut être plus utile qu’un 70B sur une tâche donnée ; un MoE de 122B n’active qu’une partie de ses paramètres par token.

La quantification rend l’inférence locale possible

En calculant grossièrement **B × 0,5 Go** pour des poids à 4 bits, un 120B demanderait environ 60 Go pour les poids seuls. Mais les fichiers réels ont des métadonnées et une quantification imparfaite ; le cache du contexte, les tampons du runtime et le système consomment aussi de la mémoire. C’est pourquoi on recommande une marge.

Taille	Poids Q4 approximatif	Conseil de mémoire
20B	11 à 14 Go	GPU 16–24 Go
30–35B	18 à 25 Go	GPU 24–32 Go / UMA
70B dense	40 à 50 Go	48–64 Go rapides
120B	65 à 85 Go	96 Go VRAM / 128 Go UMA
200B	110 à 140 Go	160–192 Go et +
300B	170 à 210 Go	192–256 Go selon Q et contexte

Q4, Q5, Q8, FP16 : plus de précision améliore parfois la fidélité mais augmente la taille en mémoire. Un Q2 peut faire tenir une architecture gigantesque, au prix de compromis potentiellement sensibles sur la qualité. Le bon choix dépend de la tâche, pas de la seule capacité de chargement.

Dense contre MoE

Un modèle **dense** mobilise la quasi-totalité de ses paramètres pour chaque étape de génération. Un **Mixture-of-Experts (MoE)** stocke beaucoup de paramètres mais n'en active qu'une petite fraction par token. Exemple : AMD présente Qwen3.5 35B-A3B avec environ 35B au total et 3B actifs ; le 122B-A10B utilise environ 10B actifs. Ces modèles peuvent générer plus vite que ne le laisse supposer leur nombre total de paramètres. [S04]

Le MoE ne supprime toutefois pas l'exigence de mémoire pour les poids : il faut que les experts utiles restent suffisamment accessibles. La vitesse dépend donc de l'architecture et de l'implémentation.

03 · La RAM, la VRAM et la bande passante

Trois architectures très différentes

Plateforme	Ce qu'elle offre	Contrepartie
RTX 5090 32 Go	VRAM GDDR7 très rapide ; CUDA ; 32 Go dédiés	Trop juste pour 70B/120B Q4 en VRAM seule
Ryzen AI Max+ 395 / 128 Go	Mémoire partagée CPU/GPU plus volumineuse	Moins de bande passante que la VRAM haut de gamme ; logiciel à valider
RTX PRO 6000 / 96 Go	96 Go GDDR7 ECC, gros débit GPU	Prix élevé, consommation jusqu'à 600 W

La RTX 5090 possède officiellement **32 Go de GDDR7**. La RTX PRO 6000 Blackwell Workstation Edition possède **96 Go GDDR7 ECC** et 1 792 Go/s de bande passante mémoire. Un Ryzen AI Max+ 395 dispose de 128 Go partagés entre CPU et GPU sur les configurations visées ; la part

réellement attribuable au GPU dépend du BIOS, du pilote et du runtime. [S09][S10]

Pourquoi la quantité seule ne garantit pas la rapidité

La génération de tokens est souvent limitée par la vitesse à laquelle le système peut lire les poids. Une mémoire GPU dédiée très rapide profite aux modèles qui y tiennent entièrement. Une mémoire unifiée volumineuse permet d'ouvrir des modèles plus grands, mais souvent à un débit inférieur. Dans les cas limites, des parties du modèle restent traitées côté CPU.

Sur Windows, l'accélération des Radeon 8060S dépend des versions logicielles. Sous Linux, les essais officiels AMD utilisent Ubuntu 24.04, ROCm et Ollama. Il faut donc distinguer la **compatibilité matérielle**, la **compatibilité runtime** et le **résultat mesuré sur le PC final**.

POINT DE VIGILANCE DOCUMENTAIRE

Une ancienne formulation du fil évoquait jusqu'à 96 Go « de VRAM » sur un Ryzen AI Max+. Ce n'est pas de la VRAM dédiée : c'est une allocation de mémoire unifiée. L'essai AMD du 122B utilisait 61 % de couches sur GPU et 39 % sur CPU dans la configuration testée.

04 · Les performances vérifiées : pas de slogans

AMD a publié des essais reproductibles sur Ryzen AI Max+ 395 avec 128 Go, Ubuntu, ROCm, Ollama et quantification Q4_K_M. Les chiffres sont ceux de la **génération**, exprimés en tokens par seconde, et non ceux d'une session Windows mesurée chez Yoann. [S04]



9B : 29,84 tokens/s ; poids autour de 6,2 Go. **35B-A3B :** 42,04 tokens/s ; environ 20,5 Go. **122B-A10B :** 8,59 tokens/s ; poids autour de 76 Go, avec une répartition 61 % GPU et 39 % CPU.

Une autre campagne indépendante utilisant **llama.cpp** et une configuration plus favorable mesure environ **22,9 tokens/s** sur ce même type de machine et modèle 122B quantifié. Cela révèle la sensibilité du résultat au moteur, à la configuration et au protocole de benchmark. [S05]

Comment interpréter 8,6, 23 ou 42 tokens/s ?

À 8,6 tokens/s, une réponse de 1 000 tokens prend théoriquement près de deux minutes de génération, hors lecture du prompt. À 23 tokens/s, un millier de tokens prend autour de 43 secondes. À 42 tokens/s, environ 24 secondes. Ces ordres de grandeur ne tiennent pas compte du temps de préparation du contexte, qui peut être important sur de gros fichiers.

Une commande de code utilisant un agent peut nécessiter des dizaines d’appels. Le critère de productivité n’est donc pas seulement le débit instantané, mais le délai jusqu’au **diff valide et vérifié**.

Ce qu’il faut mesurer après installation

- Temps de chargement du modèle et mémoire maximale occupée.
- Temps jusqu’au premier token sur 2K, 8K et 32K de contexte.
- Vitesse de génération en tokens/s, sur modèle et quantification fixés.
- Stabilité du poste lorsque Firefox, le Bridge et le runtime tournent ensemble.
- Qualité du résultat : exactitude des fichiers cités et absence de régressions.

PARTIE II

Panorama des machines

Des tours Ryzen classiques aux stations 96 Go de VRAM et aux systèmes à mémoire unifiée.

05 · Tour Ryzen 7 : développeur avant tout

Composant	Proposition
CPU	AMD Ryzen 7 9700X, 8 cœurs / 16 threads
GPU	NVIDIA RTX 5060 Ti 16 Go
Mémoire	64 Go DDR5 ; possibilité d'évolution à vérifier
Disques	2 To NVMe système + 2 To données (option)
Carte mère	B850 ou X870, 2 ports M.2 minimum
Énergie	750–850 W, bon refroidissement
Système	Windows 11 Pro

Fourchette estimée : 2 300 à 3 000 € TTC. Cette tour constitue un bon poste pour développer le JavaScript, exécuter le Bridge, gérer Git et

faire tourner de petits modèles quantifiés. Les logiciels CUDA NVIDIA sont largement pris en charge.

Son défaut pour le cahier des charges est simple : **16 Go de VRAM ne suffisent pas pour un 70B ou 120B en Q4 sans transferts massifs en RAM**. Une machine à 3 000 € ne remplit pas l'objectif prioritaire des 120B en mémoire accélérée.

Quand choisir quand même cette tour ?

Si la priorité réelle de Yoann devient le développement quotidien, la prise en charge CUDA et les LLM 7B à 20B rapides, une tour Ryzen 7 est plus évolutive et plus facile à réparer qu'un mini-PC à RAM soudée. Son GPU peut être remplacé ultérieurement.

06 · Tour Ryzen 9 et RTX 5080 / RTX 5090

Catégorie	CPU / GPU / RAM / stockage	Budget TTC
Tour haute polyvalence	Ryzen 9 9950X, RTX 5080 16 Go, 64–128 Go, NVMe 2–4 To	3 800–5 500 €
Tour IA NVIDIA rapide	Ryzen 9 9950X, RTX 5090 32 Go, 128 Go, NVMe 4–6 To	7 000–10 000 €

Un Ryzen 9 9950X possède 16 cœurs / 32 threads. Il est excellent en compilation, multitâche et traitement CPU. La RTX 5090 ajoute une énorme puissance GPU pour ComfyUI, la vidéo et les LLM de taille moyenne qui tiennent dans ses 32 Go.

Mais une tour RTX 5090 ne devient pas une station 120B « plein GPU ». Un 70B Q4 utilisera déjà davantage que les 32 Go dédiés ; un 120B demandera plus encore. Les transferts mémoire réduisent le débit.

Pourquoi ne pas la mettre n° 1 dans le budget ?

Le cahier des charges de Yoann énonce explicitement **20B → 120B et plus**. À 5 000 €, les meilleures tours GPU disponibles ont généralement trop peu de VRAM pour cette cible. Pour un développeur qui privilégie la vitesse sur 20B–35B et la compatibilité NVIDIA, le classement pourrait s'inverser.

07 · GMKtec EVO-X3 : 128 Go sous 3 500 €

Prix vérifié : 3 499,99 € TTC en variante 128 Go / SSD 2 To, boutique GMKtec France, lors de la recherche. Le fabricant annonce un Ryzen AI Max+ 395 (16 cœurs / 32 threads), une Radeon 8060S, 128 Go LPDDR5X-8000, Windows 11 Pro et une garantie de deux ans. [S01]

Élément	Caractéristique vérifiée
CPU / GPU	Ryzen AI Max+ 395 / Radeon 8060S (40 CU)
RAM	128 Go LPDDR5X-8000 soudés
SSD	2 To d'origine, deux emplacements NVMe annoncés
Réseau	Ethernet 2,5 Gb/s, Wi-Fi 7, Bluetooth 5.4
Affichage	HDMI 2.1 + USB4/DisplayPort
Extensions	OCuLink PCIe 4.0 x4, SSD NVMe
Boîtier	Mini-station, refroidissement double ventilateur
OS / garantie	Windows 11 Pro / 2 ans fabricant

Ce qu’il fait bien

- Conserver Windows pour l’interface Operator et le Bridge sans acheter une autre machine.
- Conserver 128 Go de mémoire pour des modèles Q4 dépassant 32 ou 64 Go de poids.
- Ajouter des SSD pour modèles, archives et journaux ; brancher un écran et un réseau classiques.
- Maintenir une consommation plus modérée que les stations NVIDIA multi-GPU.

Ses limites à ne pas masquer

- Mémoire soudée : pas d’augmentation à 192 Go.
- Performances GPU inférieures sur certains usages CUDA et calcul dédié ; ROCm/Vulkan demandent une vérification du runtime.
- Une seule prise Ethernet 2,5 Gb/s, contre double 10 Gb/s chez certaines alternatives.
- Le 120B fonctionne en fonction du modèle et du runtime ; il ne faut pas garantir une vitesse élevée pour un 120B dense.

Verdict : premier choix pour le budget de Yoann, parce qu’il laisse environ 1 500 € pour SSD, sauvegarde, onduleur et accessoires sans renoncer à la capacité mémoire visée.

08 · Minisforum MS-S1 MAX : plus « workstation »

Prix affiché sur Minisforum France : 3 999 € TTC en 128 Go / 2 To ; 4 319 € en 128 Go / 4 To, sous réserve de disponibilité et de la variante effectivement sélectionnée. Le fabricant mentionne deux ports 10 GbE, Wi-Fi 7, quatre ports USB4 (dont USB4 V2), une extension PCIe et un châssis permettant l’intégration en rack 2U. [S02]

Composant	Choix 128 Go / 2 To
CPU / GPU	Ryzen AI Max+ 395 / Radeon 8060S
RAM	128 Go LPDDR5X-8000 soudés
Stockage	SSD 2 To ; 2 emplacements M.2 à débits distincts
Réseau	2 × Ethernet 10 Gb/s
Extension	PCIe 4.0 x4 dans connecteur physique x16
Thermique	Modes 60, 95 et 130 W ; refroidissement renforcé
OS	Support Windows 11 Pro
Garantie	2 ans vendeur annoncés sur boutique France

Pourquoi le surcoût peut être justifié

Si Yoann envisage une station qui servira de **nœud IA sur le réseau local**, le double 10 GbE et la capacité d'intégration du MS-S1 MAX ont davantage de valeur qu'un simple tarif d'achat. L'emplacement PCIe permet certains ajouts, mais ne se substitue pas à un véritable port x16 à pleine bande passante pour plusieurs GPU.

Il reste raisonnablement dans le budget avec la version 2 To, sauvegarde et onduleur. La variante 4 To à 4 319 € atteint plus rapidement le plafond de 5 000 € après ajout des périphériques.

CHOIX COMMERCIAL

Demander au vendeur de confirmer par écrit : la variante 128 Go, l'OS installé et licencié, les modalités de livraison depuis l'UE, la garantie, le coût de retour et l'éventuelle disponibilité immédiate.

09 · Beelink GTR9 Pro : qualité d’intégration

Prix publié par la boutique européenne : 4 619 € TTC, Ryzen AI Max+ 395, Radeon 8060S, 128 Go LPDDR5X-8000, SSD 2 To. Beelink annonce deux emplacements M.2, une solution thermique double turbine/vapor chamber et du réseau 10 GbE. [S03]

Le prix de la machine laisse environ 381 € pour rester sous 5 000 €. Cela permet tout juste une sauvegarde externe et un onduleur d’entrée ou de milieu de gamme, mais **pas** le même niveau d’équipement supplémentaire qu’avec le GMKtec.

Cas où Beelink devient pertinent

Si un environnement silencieux, un boîtier bien refroidi, une garantie documentée et des interfaces réseau supérieures sont prioritairement recherchés, le Beelink est crédible. Il faut néanmoins lire les conditions effectives de garantie sur le territoire français et vérifier que le SSD 2 To est suffisamment grand pour les besoins.

Le compromis à accepter

À capacité LLM semblable (même classe de CPU, même capacité de RAM), le surcoût n’apporte pas automatiquement davantage de tokens par seconde. Il doit s’expliquer par la qualité d’intégration, la maintenance, le réseau ou le support.

10 · DGX Spark, Framework 192 Go et Mac Studio

Machine	Mémoire / environnement	Prix repère
NVIDIA DGX Spark	128 Go cohérents, GB10 ARM/Linux ; nœud IA plutôt que PC Windows	4 800 € officiel ; rupture constatée
Framework Desktop 192 Go	Ryzen AI Max PRO 495+, RAM soudée, précommande	7 659 € DIY ; 8 739 € prémonté
Apple Mac Studio M5 Ultra	256–512 Go mémoire unifiée, macOS, MLX	≈ 11 000 € et plus selon configuration

DGX Spark : NVIDIA propose 128 Go de mémoire unifiée et un écosystème IA orienté développement, avec système ARM. Le prix français de 4 800 € et la rupture de stock consultée rendent ce choix moins commode pour installer tel quel un Bridge Windows en **.exe**. [S11]

Framework 192 Go : précommandes annoncées pour novembre 2026. Le Ryzen AI Max PRO 495+ apporte davantage de mémoire et un débit RAM accru. Très intéressant pour dépasser les 120B, mais il dépasse nettement le budget maximal de Yoann. [S12]

Mac Studio M5 Ultra : les options 256 et 512 Go de mémoire unifiée et une bande passante de 1,2 To/s sont adaptées à des modèles très volumineux sous macOS. Mais un exécutable Bridge Windows ne tourne pas nativement, et le coût de la machine excède largement le plafond. [S13]

Et un portable professionnel ?

Les portables Ryzen AI Max+ à 128 Go existent, mais ils sont souvent sensiblement plus chers, avec une consommation, un bruit et un refroidissement contraints en charge longue. Pour un poste fixe d'inférence quotidienne, un mini-PC ou une tour sont plus rationnels.

11 · Stations NVIDIA et multi-GPU pour aller plus loin

Au-delà du budget, deux directions existent : **2 × RTX 5090**, soit 64 Go de VRAM répartis sur deux cartes, ou **RTX PRO 6000 Blackwell 96 Go** sur une carte professionnelle. La première demande une répartition multi-GPU compatible et un boîtier/alimentation/refroidissement adaptés ; la seconde offre une large VRAM ECC mais coûte très cher. [S09][S10]

Exemple	Composants et enveloppe	LLM visés
Double 5090	Threadripper ou Ryzen 9 adapté ; 2 × 32 Go GDDR7 ; 128 Go RAM ; 4 To SSD ; 14–28 k€	70B rapides, 120B contraints
RTX PRO 6000	Threadripper PRO, 96 Go GDDR7 ECC, 256 Go ECC RAM, SSD 4–8 To ; 22–35 k€	120B Q4 avec marge à vérifier

Le choix de plusieurs GPU suppose d'étudier les lignes PCIe, la puissance électrique, les slots disponibles, les câbles 12V-2x6 et la distribution des couches entre cartes. 2 × 32 Go ne deviennent pas une unique VRAM monolithique de 64 Go : le logiciel doit répartir explicitement le modèle.

Une station 96 Go permet à des modèles de 120B quantifiés de rester davantage sur GPU, ce qui favorise la rapidité, le contexte et parfois le multi-utilisateur. Mais il ne serait pas rationnel de conseiller cette dépense avant d'avoir caractérisé les tâches et essayé un mini-PC 128 Go.

12 · Panorama chiffré des familles de PC

Classe / configuration	Fourchette TTC	Usage dominant
Ryzen 7 + RTX 5060 Ti 16 Go	2 300–3 000 €	Code + LLM 20B
Ryzen 9 + RTX 5080 16 Go	3 800–5 500 €	Code / CUDA
Ryzen AI Max+ 395, 128 Go	3 500–4 619 €	70B / 120B Q4
DGX Spark 128 Go	≈ 4 800 €	IA Linux/ARM
Ryzen 9 + RTX 5090 32 Go	7 000–10 000 €	20–40B rapides
Framework 192 Go	7 659–12 000 €	120B et plus
Mac Studio M5 Ultra	11 000 € et plus	Très grands modèles / MLX
Double RTX 5090	14 000–28 000 €	70B et multi-GPU
Threadripper + RTX PRO 6000	22 000–35 000 €	120B pro / CUDA

Important : le prix « machine seule » et le prix « poste complet » ne doivent jamais être mélangés. Une machine de 4 619 € ne laisse que 381 € sur un plafond de 5 000 €. Un achat 3 500 € peut inclure, pour un budget identique, davantage de stockage, protection électrique et sauvegarde.

Ces plages sont des repères de discussion et non des offres fermes. Les mini-PC 128 Go disposent de prix de vente observés ; les tours et stations complexes reflètent des configurations variables de fabricants et d’assembleurs.

PARTIE III

Acheter entre 3 000 et 5 000 €

Devis, arbitrages, équipements de fiabilité et Top 3 spécifiquement adaptés à Yoann.

13 · Devis complet du GMKtec recommandé

Poste	Montant TTC	Statut
GMKtec EVO-X3 128 Go / 2 To	3 499,99 €	Prix fabricant vérifié
SSD NVMe 4 To additionnel	575,00 €	Provision haute à confirmer
Disque externe 4 To sauvegarde	170,00 €	Provision
Onduleur 1200 VA environ	190,00 €	Provision
Écran IPS 27" QHD	200,00 €	Provision
Clavier + souris	50,00 €	Provision
TOTAL DU POSTE	4 684,99 €	Estimation d’achat

Marge restante : 315,01 € sous le budget maximal de 5 000 €. Le SSD interne supplémentaire ne doit être commandé qu'après vérification de l'emplacement M.2 libre, de son format, de son débit et de son prix réel. Les accessoires sont des enveloppes budgétaires, pas des références au prix certifié.

Alternative moins chère si écran, clavier et souris existent déjà

Supprimer les 250 € d'écran et de périphériques réduirait ce devis à **4 434,99 €**. Repousser le SSD interne 4 To, en conservant les 2 To d'origine et le disque externe de sauvegarde, réduirait encore le montant à **3 859,99 €**, tout en gardant une machine apte aux essais LLM.

Allocation pratique du stockage

- SSD interne d'origine 2 To : Windows, IDE, Bridge, Git, outils et modèles de travail courants.
- SSD secondaire 4 To : grands modèles GGUF, exports, snapshots, archives et corpus de recherche.
- Disque externe 4 To : sauvegarde déconnectable, chiffrée, avec vérification périodique.
- Séparer systématiquement archives originales, fichiers temporaires et produits dérivés ; éviter les doublons gigantesques.

NE PAS OUBLIER

Le disque de sauvegarde externe doit être débranché ou isolé entre les sauvegardes. Une copie branchée en permanence n'offre pas les mêmes garanties face à un ransomware ou une mauvaise manipulation.

14 · Devis comparés à 5 000 €

Poste	Base machine	Avec sauvegarde + onduleur	Marge sur 5 000 €
GMKtec 128 Go / 2 To	3 499,99 €	3 859,99 €	1 140,01 €
Minisforum 128 Go / 2 To	3 999,00 €	4 359,00 €	641,00 €
Minisforum 128 Go / 4 To	4 319,00 €	4 679,00 €	321,00 €
Beelink 128 Go / 2 To	4 619,00 €	4 979,00 €	21,00 €

Calcul réalisé avec une **provision commune de 170 € de sauvegarde externe et 190 € d'onduleur**, hors écran, clavier, souris, éventuelle TVA supplémentaire du revendeur et frais d'installation. Ce tableau permet de comparer une base identique.

Le **Minisforum 128 Go / 4 To** est un concurrent sérieux : 4 679 € avec les deux protections de base. Il laisse toutefois peu de marge pour périphériques et imprévus. Le GMKtec reste le plus souple pour composer un poste complet.

Coûts d'exploitation qui ne figurent pas dans la facture initiale

Il faut ajouter l'électricité, les éventuels abonnements cloud, les sauvegardes futures, le remplacement du stockage et le temps de maintenance. Un PC local ne facture pas des tokens, mais coûte de l'énergie et demande un entretien. À l'inverse, un LLM cloud n'exige pas l'achat d'une station mais peut devenir coûteux en utilisation intensive.

15 · Top 3 final pour le budget confirmé

N° 1 — GMKtec EVO-X3, 128 Go : meilleur équilibre global

3 499,99 € TTC machine seule ; environ 4 685 € avec équipement complet. Il remplit la condition des 128 Go, conserve Windows et permet de financer stockage, sauvegarde et alimentation protégée. C’est mon choix par défaut pour Yoann, à condition qu’il privilégie la capacité des LLM locaux et accepte des performances variables sur 120B.

N° 2 — Minisforum MS-S1 MAX, 128 Go : meilleur profil réseau

3 999 € en 2 To ou 4 319 € en 4 To. Ses deux ports 10 GbE, son refroidissement annoncé pour les charges soutenues, son potentiel rack et son extension PCIe conviennent mieux à une future station qui fournit une API locale à plusieurs postes. Si ce scénario d’exploitation en réseau est immédiat, il peut passer devant GMKtec.

N° 3 — Beelink GTR9 Pro, 128 Go : intégration premium

4 619 € en 128 Go / 2 To. Il peut intéresser un acheteur privilégiant le refroidissement, l’intégration et le support, mais la marge budgétaire devient minuscule. Il faut donc valider précisément la garantie et les accessoires inclus.

VERDICT NON AMBIGU

Pour Agent Crypto + LLM 20B à 120B dans 5 000 €, choisir en priorité une machine Ryzen AI Max+ 395 / 128 Go. La tour Ryzen 9 RTX 5090 reste meilleure pour des modèles plus petits très rapides et l'écosystème CUDA, mais elle sort du budget et n'offre que 32 Go de VRAM dédiée.

16 · Une décision différente selon la vraie priorité

Priorité n° 1	Machine à privilégier	Pourquoi
LLM 120B à domicile	GMKtec 128 Go	Capacité / prix
Partage LAN et réseau 10 GbE	Minisforum 128 Go	Intégration et connectivité
Code + vidéo IA CUDA	Tour Ryzen 9 / GPU NVIDIA	Débit GPU et écosystème
200B/300B et plus	Framework 192 Go / Mac haut de gamme	Mémoire supplémentaire, hors budget
120B Q4 rapide et long contexte	RTX PRO 6000 96 Go	VRAM ECC rapide, hors budget

L'achat doit être conditionné à un essai logiciel ou à une vérification détaillée des configurations voisines. Un fabricant qui annonce « 128B+ » répond à la question **de la capacité**, pas nécessairement à celle de la rapidité ou de la continuité de contexte.

PARTIE IV

Les LLM et leurs outils

Une cartographie détaillée des services évoqués : fournisseurs de modèles, agrégateurs, agents de code et IA locales.

17 · Les catégories qu’il ne faut pas confondre

Catégorie	Exemples	Fonction réelle
Modèles	Claude, Gemini, Kimi, DeepSeek, Qwen, Mistral	Produisent analyse, langage et code
Agents de développement	Claude Code, Kimi Code, Vibe Code, OpenCode	Lis ent / modifient des fichiers, orchestrent des outils
Passerelles API	OpenRouter, API Mammouth	Connectent une application à des modèles
Runtimes locaux	Ollama, LM Studio, llama.cpp	Exécutent des poids du modèle sur la machine
Mémoire externe	GitHub, docs, index, Notion	Conservent la continuité documentaire

Un abonnement à une interface de chat ne fournit pas automatiquement une API, ni des crédits dans un agent de code. Une fenêtre théorique d'un million de tokens ne prouve pas qu'un dépôt entier ait été lu. Et un outil qui « prend en charge GitHub » peut n'offrir qu'une connexion limitée ou nécessiter des autorisations explicites.

Principe architectural du projet

L'objectif est de conserver la mémoire, les droits d'accès et les tests **hors du modèle**. Le LLM devient un moteur interchangeable : Claude, Kimi, Gemini, Mistral ou un modèle local. L'agent contrôle l'ouverture des fichiers et présente des preuves de son travail ; le code d'Agent Crypto vérifie les marchés et les ordres indépendamment des affirmations du LLM.

18 · Claude : développement exigeant

En octobre 2026, les documentations officielles indiquent **Claude Sonnet 5.5** et **Claude Opus 5.5**, chacun avec une fenêtre annoncée d'un million de tokens. Sonnet privilégie l'équilibre vitesse/prix ; Opus vise des travaux plus complexes. La tarification API officielle consultée est de **2 $ / 10 $** par million de tokens pour Sonnet et **4 $ / 20 $** pour Opus (entrée/sortie). [S16][S17]

Claude Code est l'outil spécialisé associé : travail sur dépôt, navigation dans les fichiers, proposition de modifications et exécution de tests sous contrôle humain. L'offre Claude Pro inclut l'accès à Claude Code, avec quota partagé et limites d'utilisation ; elle ne remplace pas un forfait API illimité. [S18]

Pourquoi l’essayer sur Agent Crypto ?

- Audit d’une architecture JavaScript conséquente.
- Réécriture minimale avec diff vérifiable et points d’entrée localisés.
- Analyse des régressions EUR/USD et du scanner sans fabriquer de données.
- Plan de correction limité à un changement effectif et une vérification reproductible.

Réserve

Même un modèle très puissant peut halluciner le contenu d’un fichier non lu, mal gérer une énorme fenêtre ou déclarer une correction trop tôt. L’acceptation doit toujours reposer sur le diff, les tests Firefox, les logs et les commits vérifiés.

19 · Gemini : grand contexte et relecture indépendante

Google décrit **Gemini 4 Argon** avec une tarification API de lancement de **2 $ / 10 $** par million de tokens jusqu’au 30 novembre 2026, puis **4 $ / 20 $** à partir du 1er décembre. Cette formule n’est pas disponible sur le niveau API gratuit. [S19]

Gemini mérite une place de **contre-expertise**, pour revoir indépendamment une architecture, un grand ensemble de documents ou la logique de calcul. L’environnement Antigravity est une piste d’atelier agentique, mais il faut vérifier les modèles réellement accessibles, les droits sur le dépôt et les quotas du compte.

Pourquoi une deuxième IA indépendante ?

Sur les défauts connus des graphiques (prix, monnaies, source, horodatage, historique), la lecture croisée de deux modèles peut révéler des hypothèses incompatibles. Cela n'est utile qu'avec des faits testables : les deux avis ne doivent pas remplacer la vérification du code et des données.

Les recherches web intégrées, les appels d'outils et les tokens de raisonnement peuvent augmenter le coût réel d'une session. Le tarif par million de tokens n'est pas le seul facteur.

20 · Kimi : conversation, projets et Kimi Code

Kimi K3.1 Pro a été annoncé le 23 octobre 2026, avec **1 million de tokens de contexte** sur les accès éligibles et des capacités orientées code, recherche financière et agents. Sur OpenRouter, le prix affiché est de **2 $ en entrée et 10 $ en sortie par million de tokens**. [S20][S21]

Il faut distinguer **Kimi Chat**, **Kimi Projets**, **Kimi Work**, **Kimi Code Desktop** et l'**API Kimi**. Ils ont des règles de mémoire, de facturation et de connexion différentes. Un abonnement de conversation ne signifie pas que toute l'inférence API de Kimi Code est incluse sans limite.

Les Projets Kimi

Kimi permet de stocker des instructions et des références dans un espace de projet persistant. La documentation indique **50 fichiers par projet**, avec une taille maximale de **100 Mo par fichier**, lus à la demande. Le niveau gratuit permet deux projets, avec stockage total limité. Les projets Chat et ceux de l'application Work sont distincts. [S22]

Pour un sous-ensemble non sensible de l'architecture documentaire, c'est intéressant ; pour une mémoire de milliers de fichiers, il faudra un routeur

de lecture et un index, pas un téléversement complet.

Kimi Code Desktop : l’élément le plus utile

Kimi Code Desktop est disponible sur **Windows**, macOS et Linux x86_64. Il ouvre un répertoire local, permet de demander une analyse, visualise les changements et possède un terminal. Il accepte aussi la configuration d’un fournisseur tiers par clé API et base URL ; une combinaison avec OpenRouter est donc plausible, sous réserve d’un test réel. [S23]

TEST DE SÉLECTION

Ouvrir une copie du dépôt en lecture seule et demander à Kimi Code de retrouver exactement la fonction du panier Top 5 et les sources de séries. Refuser toute déclaration « lu » sans chemin de fichier et portion de code vérifiable.

21 · Mistral : alternative française et Vibe Code

Mistral Large 4 a été présenté le 6 octobre 2026 en préversion publique, avec une architecture MoE et un contexte annoncé de 1M tokens. Sa documentation affiche une tarification variable : il faut toujours consulter la fiche du jour avant de faire un budget API. C’est un candidat de comparaison sérieux, pas une garantie de compatibilité immédiate avec un environnement local à 128 Go. [S24]

Mistral Vibe Code peut travailler dans un dossier, lire des fichiers, exécuter des commandes, modifier du code et ouvrir des demandes de fusion, sous supervision humaine. Il fonctionne notamment en terminal et VS Code. Certains réglages permettent d’exiger l’accord avant les modifications. [S25]

Intérêt pour Yoann

- Écosystème européen utile à examiner pour des raisons de fournisseur et de langue.
- Alternative indépendante pour vérifier une anomalie identifiée par un autre agent.
- Possibilité d'utiliser un agent local tout en maîtrisant les permissions sur les fichiers.

Réserve

Poids ouverts ne signifie pas petit modèle : un LLM MoE totalisant des centaines de milliards de paramètres peut être impossible à héberger dans 128 Go, même si peu d'experts sont actifs à chaque token. Il faut distinguer les modèles API et les modèles locaux réellement installables.

22 · DeepSeek, Qwen et modèles économiques

DeepSeek : un bon candidat au second regard économique

DeepSeek V4.1-Flash possède une API officielle, avec une structure tarifaire dépendant des heures pleines et creuses. La documentation est préférable aux vieux articles de prix. Le modèle **deepseek-flash** prend en charge l'appel d'outils et les sorties structurées. [S26]

Pour des résumés documentaires, des vérifications simples et des tâches où l'on peut répéter les tests, un modèle économique peut offrir un bon coût par résultat. Pour la mémoire privée, la politique du fournisseur doit être examinée avant d'envoyer des données.

Qwen : deux choses très différentes

Qwen cloud regroupe de grands modèles servis à distance, par exemple Qwen3.8-Max. **Qwen local** regroupe des poids de dimensions plus modestes ou d'architectures MoE ; ce sont eux qu'on peut envisager sur les 128 Go de Yoann. La qualité et la mémoire requises varient énormément. [S27]

Les premiers modèles à éprouver localement sur Ryzen AI Max+ sont **Qwen3.5 9B**, **Qwen3.5 35B-A3B** et, pour la capacité maximale, **Qwen3.5 122B-A10B Q4_K_M**, précisément parce que des mesures publiques existent pour ces variantes. [S04]

Un 120B local est-il automatiquement « meilleur » ?

Non. Selon le code, le contexte et le temps disponible, le 35B MoE peut fournir une meilleure expérience que le 122B. La taille du modèle n'est pas un substitut à la vérification des sorties, des outils et des permissions.

23 · GLM, MiniMax, Grok et autres alternatives

Le fil a également examiné **GLM (Z.ai), MiniMax et Grok (xAI)** parmi les candidats d'audit ou de comparaison. Ces familles peuvent être intéressantes pour disposer de lectures indépendantes, mais leurs versions, endpoints, fenêtres de contexte et prix évoluent rapidement : il faut interroger les documentations officielles ou le catalogue OpenRouter avant de les intégrer dans un budget ferme.

Il n'y a pas de raison d'installer dix fournisseurs à la fois. Les difficultés passées du projet montrent que la dispersion peut coûter plus que la diversité. Une procédure plus robuste consiste à choisir un **modèle principal**, **un vérificateur indépendant**, puis **un secours économique**.

Rôle	Candidats	Mission
Principal code	Kimi Code / Claude Code	Lire, corriger, produire diff
Vérification indépendante	Gemini / Mistral	Relire calculs et risques
Économique cloud	DeepSeek / Qwen via API	Synthèses et petites tâches
Local / privé	Qwen3.5 via Ollama/LM Studio	Routage, réponses hors réseau

24 · OpenRouter : le routeur cloud, pas la mémoire

OpenRouter fournit une API unifiée vers un grand catalogue de modèles et de fournisseurs. La formule gratuite a des limites de requêtes ; la formule Standard utilise des crédits à l'usage. **La commission de plateforme de 5,5 % s'applique à l'achat de crédits**, et non à chaque requête, selon la page de tarification officielle. [S28]

Pourquoi c'est bien aligné avec une architecture indépendante

- Changer le modèle par identifiant explicite sans reconstruire l'application cliente.
- Conserver un journal des appels, des coûts et des échecs.
- Utiliser un modèle cher seulement pour les décisions complexes.
- Sélectionner le fournisseur et des politiques de confidentialité selon les options du compte.
- Maintenir les règles métier et la mémoire documentaire hors de l'API.

Ce que OpenRouter ne fournit pas par magie

Il ne fournit pas automatiquement un agent qui teste Firefox, modifie Git et produit un ZIP. Pour cela il faut OpenCode, un outil équivalent ou une couche applicative dédiée. Il ne garantit pas non plus que tous les fournisseurs respectent les mêmes règles de conservation ou de résidence des données.

Confidentialité

OpenRouter indique ne pas entraîner ses propres modèles sur les données des clients. Les requêtes sont toutefois transmises aux fournisseurs sous-jacents. Des options de routage Zero Data Retention existent, mais un échange cloud reste un échange qui quitte l'ordinateur. Pour les archives privées, préférer le local ou une sélection de fichiers contrôlée. [S28]

25 · Mammouth AI : pourquoi rester prudent

Mammouth est un agrégateur orienté **confort d'accès à de nombreux modèles**. Les plans publiés au moment de la recherche affichent **12 $, 24 $ et 72 $ par mois hors taxes** (Starter, Standard, Expert), avec un accès à plusieurs familles de LLM. Mais la politique officielle confirme un **quota renouvelé toutes les trois heures** et une **substitution automatique vers un modèle plus léger** lorsque le seuil du modèle initial est atteint. [S29][S30]

Exemple documenté : Claude Opus → Claude Sonnet → Claude Haiku après franchissement des seuils. Les messages longs, les documents, le contexte cumulé et les outils consomment davantage de quota.

Pourquoi ce mécanisme importe pour Agent Crypto

Un audit commencé sur un modèle avancé peut continuer sur un modèle moins puissant. C’est une solution pertinente pour ne pas interrompre un usage grand public, mais pas nécessairement une garantie de capacité identique sur une tâche d’ingénierie compliquée.

Le service n’est pas seulement un chat

Mammouth propose aussi **Mammouth Code** et une API compatible OpenAI. Mais les **crédits API sont distincts** des quotas de chat : l’abonnement inclut seulement 2 $, 4 $ ou 10 $ de crédits selon le plan. La documentation conseille même un forfait modeste avec crédits additionnels pour l’usage intensif en développement. [S31]

Conclusion équilibrée

Il serait excessif d’affirmer que les modèles sont forcément volontairement bridés ou que tous les agrégateurs sont des vendeurs de rêves. Ce que les documents prouvent, c’est un ensemble de compromis : quotas, contexte transmis, outils différents et modèle de remplacement. Pour le travail de Yoann, je ne ferais pas de Mammouth le moteur principal sans essai contradictoire.

26 · Grille de comparaison : choisir une vraie capacité

Solution	Usage fort	Limite à mesurer
Claude Code	Code, correction délicate	Quota et coût
Kimi Code	Dossier local Windows	Modèles et droits disponibles

Solution	Usage fort	Limite à mesurer
Gemini / Antigravity	Contre-expertise, long contexte	Conditions du compte
Mistral Vibe Code	Agent de code alternatif	Permissions et qualité du diff
OpenRouter	Passerelle multimodèle	Fournisseur, politique, coûts
Mammouth	Comparaison rapide en chat	Quota, bascule de modèle
Ollama / LM Studio	Inférence locale	Pilotes, mémoire, débit
OpenCode	Atelier agnostique au modèle	Configuration, sécurité, outils

Recommandation : essayer d'abord Kimi Code ou un agent équivalent sur une copie du dépôt, puis brancher OpenRouter seulement si un besoin multimodèle effectif est démontré. Tester Qwen local séparément, sans confondre ses performances avec celles de Kimi ou Claude cloud.

27 · Les coûts API : exemples simples

Les modèles cloud sont généralement facturés par million de tokens d'entrée et de sortie. La facturation de la recherche web, des outils, du cache et du raisonnement peut ajouter des lignes spécifiques. Les exemples ci-dessous ne comprennent ni TVA, ni commission de recharge, ni frais d'outils.

Modèle / tarif API vérifié	Entrée / 1M	Sortie / 1M
Claude Sonnet 5.5	2 $	10 $

Modèle / tarif API vérifié	Entrée / 1M	Sortie / 1M
Claude Opus 5.5	4 $	20 $
Gemini 4 Argon (jusqu'au 30/11)	2 $	10 $
Kimi K3.1 Pro / OpenRouter	2 $	10 $
Mistral Large 4	variable / aperçu tarifaire	variable / aperçu tarifaire

Exemple de mission : 100 000 tokens d'entrée et 10 000 de sortie sur un modèle à 2 $ / 10 $ par million coûtent **0,30 $** de tokens de base (0,20 $ entrée + 0,10 $ sortie). Répétée cent fois, cela représente **30 $**, hors outils et frais. Une requête envoyant toujours la totalité du contexte peut coûter beaucoup plus cher qu'une lecture ciblée.

La métrique la plus utile

Comparer **le coût par correction acceptée** : le modèle a-t-il identifié la bonne fonction, respecté les cinq séries, produit le diff demandé et permis de confirmer le résultat dans Firefox ? Le prix par token est secondaire lorsque des régressions obligent à tout recommencer.

PARTIE V

Installer et vérifier

Le plan d’architecture, les tests logiciels, la sécurité du Bridge et les étapes qui permettent de savoir si l’achat est réussi.

28 · Architecture de déploiement proposée

Le PC de Yoann peut héberger simultanément le projet, les outils de développement et un runtime local. Mais les processus doivent rester indépendants pour éviter qu’un modèle qui sature la mémoire n’interrompe le Bridge ou une lecture du marché.

Couche	Outils	Responsabilité
Poste Windows	Firefox, Operator/Admin, Git, VS Code	Interface et travail quotidien
Bridge / backend	Services existants, journaux	Connexion et données autorisées
LLM local	Ollama, LM Studio ou llama.cpp	Inférence hors cloud
Agent de code	OpenCode / Kimi Code / Claude Code	Lecture et modifications contrôlées
Mémoire	Git, export Notion, index, archives	Sources vérifiées et continuité

Couche	Outils	Responsabilité
Validation	Contrôles déterministes, Firefox	Preuves, non promesses

Exemples de routage des tâches

Une demande « retrouver la source de la courbe ETH » route vers le code des séries et la documentation des flux ; une demande « corriger le chargement Top 5 » route vers les modules UI et le scanner ; une demande « expliquer une valeur P&L » route vers la méthode de calcul. Tout l'historique du projet n'a pas à être injecté systématiquement.

Principe de sécurité : une IA qui analyse le code ne doit pas disposer par défaut des identifiants de trading ou de la possibilité d'émettre un ordre. Le passage d'un mode lecture seule à un mode action exige des contrôles indépendants et une autorisation humaine.

29 · Windows d'abord, Linux pour comparer

Étape A : Windows 11 Pro. Installer Firefox, Git, l'environnement Operator/Bridge, les pilotes AMD actualisés puis un runtime local compatible. Vérifier que les historiques, les graphiques et les journaux fonctionnent avant d'activer le LLM.

Étape B : modèles locaux compacts. Tester Qwen3.5 9B, puis 35B MoE, avec une méthode identique et des réglages consignés. Le 35B sera le candidat de travail quotidien si les performances observées sont acceptables.

Étape C : 122B. Essayer la variante quantifiée explicitement prise en charge par l'environnement, mesurer mémoire et vitesse ; ne pas forcer de paramètres BIOS agressifs sans documentation et possibilité de

restauration.

Étape D : Linux optionnel. Si les performances sous Windows restent limitées ou le GPU mal exploité, évaluer séparément un SSD Linux avec Ubuntu/ROCm et les procédures AMD. Le Bridge Windows doit rester opérationnel sur sa plateforme initiale tant que sa migration n'a pas été validée.

Pourquoi ne pas migrer tout le projet sous Linux immédiatement ?

Cela mélangerait deux risques : la migration de l'application et celle du moteur local. Il vaut mieux garder une version de référence stable du Bridge sous Windows, puis comparer les vitesses des runtimes sur Linux sans modifier les interfaces financières.

30 · Tester la vérité du modèle, pas son discours

Le problème récurrent dans les longs projets IA est qu'un agent peut déclarer avoir lu, corrigé ou livré sans preuve correspondante. Le protocole de validation proposé vise précisément cette situation.

Épreuve 1 — Inventaire des fichiers

- Le modèle localise le vrai fichier, son chemin et son état ; il signale explicitement les fichiers absents.
- Il n'invente ni méthode, ni règle de marché, ni données historiques.
- Il ne charge pas toute la mémoire par réflexe : il sélectionne les sources utiles.

Épreuve 2 — Traçabilité EUR/USD

- Il identifie pour une courbe la paire, la source, la devise, l’horodatage et la fenêtre d’historique.
- Il sépare faits constatés, hypothèses de bug et preuves de correction.
- Il préserve la distinction USD / EUR, et USD / USDT / USDC lorsque le code la requiert.

Épreuve 3 — Panier Top 5 et séries historiques

- Il préserve BTC, ETH, BNB, XRP et SOL ; pas de stablecoins dans ce panier.
- Il signale toute série manquante au lieu de fabriquer une ligne plate ou une interpolation.
- Il exige cinq séries réelles et cohérentes si l’opération requiert cinq séries.

Épreuve 4 — Modification contrôlée

- Proposer un diff précis, localisé, lisible ; pas de réécriture massive non motivée.
- Expliquer ce qui change réellement et ce qui reste inchangé.
- Tester localement, puis seulement déclarer la correction validée et proposer le commit.

RÈGLE D’ACCEPTATION

Une réponse convaincante ne suffit pas. La preuve est un fichier réellement lu, un diff réel, des journaux, une vérification de l’interface et un comportement reproductible. Si ces éléments manquent, le statut doit rester « non vérifié ».

31 · Le Bridge et les données financières

L'Operator et le Bridge représentent une zone plus sensible que la simple lecture d'un PDF. Les données de marché peuvent être périmées, hétérogènes ou mal alignées sur les devises. Les ordres éventuels doivent rester soumis aux contrôles indépendants du langage naturel.

Contrôles recommandés

- Mode lecture seule par défaut ; aucune clé sensible exposée aux prompts.
- Contrôle d'identité de chaque série (actif, source, marché, devise, fuseau, timestamp, nombre de points).
- Journalisation des requêtes, échecs, temps de réponse et caches, avec limites de rétention.
- Validation systématique des sorties du LLM avant de modifier une règle financière.
- Procédure de retour arrière et version sûre conservée.
- Backups réguliers avec empreintes des archives importantes et des fichiers livrés.

Les erreurs du type « prix en EUR présenté comme USD » ou « série affichée avant synchronisation complète » doivent être corrigées par le programme et ses tests, pas masquées par une explication du modèle.

32 · Mémoire externe et confidentialité

La mémoire d’un projet ne doit pas être assimilée à la taille de fenêtre du modèle. Un système de mémoire utile contient un **index**, des sources canoniques, un protocole de sélection et une traçabilité de la lecture effective. Les fichiers disponibles ne sont pas nécessairement chargés ; les fichiers chargés ne sont pas nécessairement correctement appliqués.

Trois niveaux de données

- **Public / transmissible :** documentation technique, modèles de prompts réutilisables, méthodes génériques, sources de benchmark.
- **Projet privé :** code non public, journaux, architecture, décisions de versions, informations opératoires nécessaires.
- **Très sensible :** secrets, identifiants, informations personnelles, clés API et détails financiers privés. Ne jamais envoyer par défaut à un LLM cloud.

OpenRouter, Kimi, Anthropic et Mistral ont des politiques et sous-traitants qui évoluent ; il faut vérifier les réglages propres au compte et au mode API. Le chemin local demeure le meilleur choix pour les données qui ne doivent pas quitter le poste.

GitHub et Notion : des sources, pas des permissions implicites

Un outil connecté à un dépôt ne devrait pas recevoir les droits d’écriture lors d’un premier essai. Il faut lui donner accès à une copie, puis vérifier les chemins, hashes, diffs et sorties. Une connexion à Notion ne prouve pas qu’une longue page a été lue en totalité.

33 · Évaluer les IA sur le même chantier

Tester successivement Kimi Code, Claude Code, un agent Gemini/Vibe, puis un modèle local Qwen. Ne pas attribuer des tâches différentes à chaque candidat au premier tour : l'objectif est la comparaison équitable.

Critère	Comment mesurer	Résultat attendu
Lecture du code	Chemins et lignes cités	Aucun fichier inventé
Diagnostic	Cause, preuve, incertitude	Conclusion falsifiable
Respect des règles	Top 5 / devises / 5 séries	Pas de substitution
Qualité du diff	Patch restreint, sans casse	Révision simple
Exécution	Test Firefox / journal	Preuve de résultat
Coût et durée	Temps et tokens effectifs	Coût par tâche validée
Confidentialité	Données quittant la machine ?	Politique explicite

Il faut répéter chaque essai sur un snapshot identique et conserver les logs. Lorsqu'un fournisseur a un quota, vérifier si le modèle a changé pendant l'épreuve. Les sessions de plusieurs heures doivent mentionner leur consommation réelle et les éventuels messages tronqués.

34 · Plan de mise en service en quatre étapes

Étape 1 — Réception et contrôle matériel

Vérifier modèle exact du CPU, 128 Go reconnus, SSD installé, version du BIOS, licence Windows, alimentation EU, connectique, fonctionnement du refroidissement, réseau et garanties. Réaliser la sauvegarde de l’installation de référence avant d’ajouter les outils IA.

Étape 2 — Agent Crypto sans IA

Installer la copie validée du projet, Firefox, les composants du Bridge et le backend. Vérifier les fonctions de base, les journaux et la séparation lecture/écriture. Établir un point de reprise avant toute automatisation.

Étape 3 — IA locale mesurée

Installer un runtime, choisir un 9B puis 35B MoE, enregistrer les paramètres et les vitesses. Tenter ensuite le 122B Q4. Éviter de déclarer « 120B opérationnel » sans mesures de mémoire et de délai sur un prompt représentatif.

Étape 4 — Agent de code et comparaison cloud

Ouvrir une copie de dépôt en lecture seule dans Kimi Code ou OpenCode ; appliquer le référentiel de tests ; ne donner les droits de modification qu’après le premier succès démontré. Évaluer OpenRouter seulement si l’accès à plusieurs modèles simplifie réellement le travail.

35 · Checklist avant commande

- ☐ Variante exactement **128 Go LPDDR5X** et non 64 Go.
- ☐ CPU Ryzen AI Max+ 395 et Radeon 8060S correctement identifiés.
- ☐ Prix TTC, livraison depuis l'Union européenne, facturation professionnelle.
- ☐ Système Windows 11 Pro installé/licencié ou modalités explicites.
- ☐ Stock disponible, délai réel et droit de retour confirmés.
- ☐ Garantie et procédure de prise en charge en France confirmées.
- ☐ Emplacement NVMe libre et compatibilité du SSD prévu.
- ☐ Ports réseau suffisants pour le Bridge et le réseau local.
- ☐ Écran / clavier / souris existants ou intégrés au budget.
- ☐ Onduleur adéquat, sauvegarde chiffrée et emplacement physique prévu.
- ☐ Objectif mesurable : 35B MoE confortable, 122B quantifié testable.
- ☐ Aucune promesse de trading autonome ou de rendement attachée à l'achat.

36 · Recommandations finales de décision

Choix prioritaire : GMKtec EVO-X3, Ryzen AI Max+ 395 / 128 Go / 2 To, environ 3 500 € machine seule. Le budget total détaillé est d'environ 4 685 € avec stockage supplémentaire, sauvegarde, onduleur et poste de travail. Pour Yoann, c'est l'option offrant le plus de souplesse financière tout en atteignant l'objectif de capacité mémoire.

Alternative n° 2 : Minisforum MS-S1 MAX 128 Go. Si la machine doit être installée comme nœud IA professionnel partagé sur le réseau local, le double 10 GbE et l'intégration rack ont une valeur concrète. Sa version 4 To peut être un meilleur achat que le GMKtec plus SSD ajouté, selon les

garanties et le prix du moment.

Alternative n° 3 : Beelink GTR9 Pro 128 Go. À considérer si le niveau de finition, le refroidissement et le support commercial justifient le surcoût. Dans 5 000 €, prévoir déjà l'essentiel de la sauvegarde et de la protection électrique.

Choix des modèles et logiciels

En local : commencer par **Qwen3.5 35B MoE**, puis mesurer le **122B MoE**. Pour un travail de code exigeant dans un dépôt réel : évaluer **Kimi Code**, puis **Claude Code** ou **Mistral Vibe Code** en relecture. **OpenRouter** est une passerelle intéressante si plusieurs moteurs cloud doivent être sélectionnés à coût contrôlé. **Mammouth** reste secondaire à cause des quotas et de la substitution possible de modèle.

CONCLUSION DE TOUT LE DOSSIER

Le meilleur achat ne se mesure ni au nombre de TOPS, ni aux milliards de paramètres, ni au nombre d'IA affichées dans une offre. Il se mesure au travail vérifié : Agent Crypto stable, mémoire protégée, modèles locaux utilisables, correctifs traçables et liberté de changer de fournisseur.

PARTIE ANNEXES

Références et méthodes

Calculs, lexique de lecture et liens consultables depuis le téléphone ou l'ordinateur.

A · Lexique essentiel

Terme	Signification pratique
B / milliard	Nombre de paramètres du modèle
LLM dense	Presque tous les paramètres utilisés par token
MoE	Architecture avec experts sélectionnés à chaque token
Q4_K_M	Format de quantification 4 bits courant
VRAM	Mémoire dédiée au GPU, souvent très rapide
UMA	Mémoire partagée CPU/GPU ; allocation dépend du système
Cache KV	Mémoire servant à gérer le contexte de génération
tok/s	Débit de génération de tokens par seconde
Prefill	Traitement initial des tokens du prompt

Terme	Signification pratique
Runtime	Logiciel qui exécute effectivement les poids du modèle
API	Interface logicielle pour appeler un service
Agent de code	Outil capable de lire / écrire / tester un projet
Diff	Liste précise des modifications de fichiers
Snapshot	État figé pour comparaison et restauration

B · Exemples de calculs

Calcul d’un besoin mémoire

Pour **120 milliards de paramètres**, Q4 idéal : 120 × 0,5 ≈ **60 Go pour les poids seuls**. Ajouter le surcoût du format réel, les activations, le cache KV et le système peut conduire à 65–85 Go ou davantage selon contexte. Un modèle Q4 de 76 Go peut donc exiger une machine 128 Go pour conserver une marge suffisante.

Calcul du devis principal

3 499,99 + 575 + 170 + 190 + 200 + 50 = **4 684,99 €**. 5 000 − 4 684,99 = **315,01 €**. Le seul prix de machine fixé par une source commerciale dans ce calcul est 3 499,99 € ; les autres montants sont des provisions.

Calcul simplifié de coût API

100 000 tokens en entrée à 2 $/million : **0,20 $**. 10 000 tokens en sortie à 10 $/million : **0,10 $**. Ensemble : **0,30 $** par opération. Ce calcul ignore le cache, les outils, les frais de recharge et les taxes, et ne garantit pas que l'opération soit correcte.

C · Sources vérifiables et liens directs

Les références [Sxx] renvoient à des pages de fabricants ou des documentations techniques consultées pour le dossier. Les prix et disponibilités sont datés du 31 octobre 2026, susceptibles de changer ; les liens sont cliquables dans le PDF. Les pages commerciales peuvent varier selon la variante sélectionnée.

[S01] GMKtec EVO-X3, 128 Go / 2 To, France
https://gmktec.fr/products/gmktec-evo-x3-amd-ryzen%E2%84%A2-ai-max-395-mini-pc-ia

[S02] Minisforum MS-S1 MAX, configurations et prix FR
https://minisforumpc.fr/products/minisforum-ms-s1-max

[S03] Beelink GTR9 Pro, fiche et boutique Europe
https://eu.bee-link.com/products/beelink-gtr9-pro-amd-ryzen-ai-max-395

[S04] AMD ROCm, Ryzen AI Max et benchmarks Qwen 9B/35B/122B
https://rocm.blogs.amd.com/artificial-intelligence/ryzen-uma-llm/README.html

[S05] llm-bench, comparaisons reproductibles de runtimes
https://github.com/BAEM1N/llm-bench

[S06] AMD Ryzen AI Max+ 395, plateforme AMD
https://www.amd.com/en/products/processors/laptop/ryzen/ai-max-series/amd-ryzen-ai-max-plus-395.html

[S07] Ollama, téléchargement et modèles
https://ollama.com/

[S08] LM Studio, IA locale sur Windows
https://lmstudio.ai/

[S09] NVIDIA RTX 5090, 32 Go GDDR7
https://www.nvidia.com/fr-fr/geforce/graphics-cards/50-series/rtx-5090/

[S10] NVIDIA RTX PRO 6000 Blackwell, 96 Go ECC
https://www.nvidia.com/fr-fr/products/workstations/professional-desktop-gpus/rtx-pro-6000/

[S11] NVIDIA DGX Spark, boutique et spécifications France
https://marketplace.nvidia.com/fr-fr/enterprise/personal-ai-supercomputers/dgx-spark/

[S12] Framework Desktop 192 Go, annonce fabricant
https://frame.work/blog/192gb-framework-desktop-open-for-pre-order

[S13] Apple Mac Studio M5 Ultra, spécifications
https://support.apple.com/fr-fr/128107

[S14] OpenCode, fournisseurs et runtime local
https://opencode.ai/v2/docs/providers

[S15] Kimi Code Desktop, guide de démarrage
https://www.kimi.com/code/docs/en/kimi-code-desktop/getting-started.html

[S16] Claude Sonnet 5.5, fiche officielle
https://platform.claude.com/docs/en/models/sonnet-5-5/overview

[S17] Claude Opus 5.5, fiche officielle
https://platform.claude.com/docs/en/models/opus-5-5/overview

[S18] Claude, tarifs et présence de Claude Code dans Pro
https://claude.com/fr/pricing

[S19] Gemini 4 Argon, tarification Google
https://ai.google.dev/gemini-api/docs/latest-model?hl=fr

[S20] Kimi K3.1 Pro, annonces Kimi Code
https://www.kimi.com/code/docs/en/kimi-code/whats-new.html

[S21] Kimi K3.1 Pro, fiche et tarif OpenRouter
https://openrouter.ai/moonshotai/kimi-k3.1-pro

[S22] Kimi Projets, limites et fonctionnement
https://www.kimi.ai/fr/help/features/project

[S23] Kimi Code Desktop, fournisseurs externes
https://www.kimi.ai/help/kimi-code/desktop-getting-started

[S24] Mistral Large 4, documentation officielle
https://docs.mistral.ai/fr/models/mistral-large-4-0

[S25] Mistral Vibe Code, outil de développement
https://docs.mistral.ai/vibe/code/overview

[S26] DeepSeek, modèles et prix API officiels
https://api-docs.deepseek.com/quick_start/pricing/

[S27] Qwen 3.8 Max, annonce Alibaba
https://www.alibabagroup.com/en-US/document-2021044032125272064

[S28] OpenRouter, prix, quotas, politique de confidentialité
https://openrouter.ai/pricing

[S29] Mammouth, offres et tarifs affichés
https://mammouth.ai/pricing

[S30] Mammouth, règles de quotas et bascule
https://info.mammouth.ai/fr/docs/quota-policy/

[S31] Mammouth, crédit API et Mammouth Code
https://info.mammouth.ai/fr/docs/api-quick-start/